

## 5. sklop: Normalni model z dvema parametroma

Nina Ruzic Gorenjec

### 1 Primer

Podan imamo naslednji vzorec visin (metri) studentov moskega spola:

```
x <- c(1.91, 1.94, 1.68, 1.75, 1.81, 1.83, 1.91, 1.95, 1.77, 1.98,  
       1.81, 1.75, 1.89, 1.89, 1.83, 1.89, 1.99, 1.65, 1.82, 1.65,  
       1.73, 1.73, 1.88, 1.81, 1.84, 1.83, 1.84, 1.72, 1.91, 1.63)
```

Zanima nas povprečna visina studentov, kjer standardnega odklona ne poznamo.

### 2 Verjetnostni model za nas primer

Vzorec  $X_1, X_2, \dots, X_n$ , kjer je:

- $n = 30$  stevilo studentov,
- $X_i$  predstavlja visino  $i$ -tega studenta,
- $X_i \mid \mu, \sigma^2 \sim N(\mu, \sigma^2)$ ,
- $f(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ .

Prostor parametrov je dvorazsežen:  $\theta = (\mu, \sigma^2) \in \mathbb{R} \times (0, \infty)$ .

### 3 Ocenjevanje v Bayesovi statistiki

Bayesova formula:

$$\pi(\mu, \sigma^2 \mid x) \propto L(\mu, \sigma^2 \mid x) \pi(\mu, \sigma^2).$$

Nastaviti moramo torej dvorazsežno apriorno porazdelitev in dobiti dvorazsežno aposteriorno porazdelitev.

#### 3.1 Verjetje

$$L(\mu, \sigma^2 \mid x) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

## 3.2 Apriorna porazdelitev

Vedno velja (pogojna verjetnost):

$$\pi(\mu, \sigma^2) = \pi(\mu \mid \sigma^2) \cdot \pi(\sigma^2).$$

### 3.2.1 Konjugirana apriorna porazdelitev

Za  $\mu \mid \sigma^2$  vzamemo

$$\mu \mid \sigma^2 \sim N(\mu_0, \sigma^2/\kappa_0).$$

Porazdelitev  $\sigma^2$  lahko zapisemo na tri ekvivalentne nacine:

$$\sigma^2 \sim \text{Inv-Gama}(\nu_0/2, \nu_0 \sigma_0^2/2),$$

kar pomeni ravno

$$1/\sigma^2 \sim \text{Gama}(\nu_0/2, \nu_0 \sigma_0^2/2),$$

kar je ekvivalentno

$$\nu_0 \sigma_0^2/\sigma^2 \sim \text{Gama}(\nu_0/2, 1/2) = \chi_{\nu_0}^2.$$

**Ideja za parametre apriorne porazdelitve:**

- $\mu_0$  je nase prepricanje o  $\mu$
- $\sigma_0^2$  je nase prepricanje o  $\sigma^2$  (ker je ravno pricakovana vrednost)
- vecji kot je  $\nu_0$  oz.  $\kappa_0$ , bolj verjamete, da je  $\mu$  enak  $\mu_0$  oz.  $\sigma^2$  enak  $\sigma_0^2$
- $\kappa_0$  oz.  $\nu_0$  predstavljata velikost vzorca, na podlagi katerega je vase prepricanje o  $\mu$  oz.  $\sigma^2$  osnovano

### 3.2.2 Neinformativna apriorna porazdelitev

Privzamemo neodvisnost apriornih porazdelitev parametrov:

$$\pi(\mu, \sigma^2) = \pi(\mu) \cdot \pi(\sigma^2).$$

Jeffreyeva apriorna porazdelitev za  $\mu$  v normalnem modelu z znanim  $\sigma^2$ :

$$\pi(\mu) \propto \sqrt{1/\sigma^2} \propto 1.$$

Jeffreyeva apriorna porazdelitev za  $\sigma^2$  v normalnem modelu z znanim  $\mu$ :

$$\pi(\sigma^2) \propto 1/\sigma^2.$$

Dobimo torej

$$\pi(\mu, \sigma^2) \propto 1/\sigma^2,$$

kar je seveda *improper* porazdelitev.

### 3.3 Aposteriorna porazdelitev

Tudi tu vedno velja (pogojna verjetnost):

$$\pi(\mu, \sigma^2 \mid x) = \pi(\mu \mid \sigma^2, x) \cdot \pi(\sigma^2 \mid x).$$

#### 3.3.1 Aposteriorna porazdelitev pri konjugirani apriorni porazdelitvi

Dobimo:

$$\mu \mid \sigma^2, x \sim N(\mu_n, \sigma^2 / \kappa_n),$$

kjer je

$$\begin{aligned} \kappa_n &= \kappa_0 + n, \\ \mu_n &= \frac{\kappa_0}{\kappa_0 + n} \mu_0 + \frac{n}{\kappa_0 + n} \bar{x}. \end{aligned}$$

Aposteriorno porazdelitev  $\sigma^2$  lahko zapisemo na tri ekvivalentne načine:

$$\begin{aligned} \sigma^2 \mid x \sim \text{Inv-Gama}(\nu_n/2, \nu_n \sigma_n^2/2) &\iff 1/\sigma^2 \mid x \sim \text{Gama}(\nu_n/2, \nu_n \sigma_n^2/2) \iff \\ &\iff \nu_n \sigma_n^2 / \sigma^2 \mid x \sim \text{Gama}(\nu_n/2, 1/2) = \chi_{\nu_n}^2, \end{aligned}$$

kjer je

$$\begin{aligned} \nu_n &= \nu_0 + n, \\ \nu_n \sigma_n^2 &= \nu_0 \sigma_0^2 + (n-1)s^2 + \frac{n\kappa_0}{\kappa_0 + n} (\bar{x} - \mu_0)^2. \end{aligned}$$

**Ideja:**

- Aposteriorna pričakovana vrednost  $\mu_n$  je utezeno povprečje apriorne pričakovane vrednosti  $\mu_0$  in vzorčnega povprečja  $\bar{x}$ , kjer preko  $\kappa_0$  kontroliramo, kako močno verjamemo apriorni pričakovani vrednosti, medtem ko  $n$  določa, kako močno verjamemo vzorcu.
- Na ravni vsote kvadratov odstopanj je aposteriorna enaka vsoti apriorne, vzorčne in zadnjega člena, ki je posledica pogojne odvisnosti  $\mu$  od  $\sigma^2$ .

```
### Izberemo parametre apriorne porazdelitve
mu.0 <- 1.78
kappa.0 <- 1

sigma2.0 <- 0.1^2
nu.0 <- 1

### Izračunamo parametre aposteriorne porazdelitve
n <- length(x)

kappa.n <- kappa.0 + n
mu.n <- kappa.0/kappa.n * mu.0 + n/kappa.n * mean(x)

nu.n <- nu.0 + n
```

```

sigma2.n <- ( nu.0*sigma2.0 + (n-1)*var(x) +
              n*kappa.0/kappa.n * (mean(x)-mu.0)^2 ) / nu.n

### Narisemo porazdelitev
# Prvi nacin: s parametrom 1/sigma^2
mu <- seq(1.7, 1.9, 0.0001)
prec2 <- seq(50, 170, 1)

apost <- matrix(NA, nrow = length(mu), ncol = length(prec2))
for (i in 1:length(mu)) {
  for (j in 1:length(prec2)) {
    apost[i, j] = dnorm(mu[i], mean = mu.n, sd = sqrt(1/(kappa.n*prec2[j]))) *
                  dgamma(prec2[j], nu.n/2, nu.n*sigma2.n/2)
  }
}


par(mfrow = c(1,2))
contour(mu, prec2, apost)

# Drugi nacin: s parametrom sigma^2
#install.packages("invgamma")
library(invgamma)
mu <- seq(1.7, 1.9, 0.0001)
sigma2 <- seq(1/170, 1/50, 0.001)

apost <- matrix(NA, nrow = length(mu), ncol = length(sigma2))
for (i in 1:length(mu)) {
  for (j in 1:length(sigma2)) {
    apost[i, j] = dnorm(mu[i], mean = mu.n, sd = sqrt(sigma2[j]/kappa.n)) *
                  dinvgamma(sigma2[j], shape=nu.n/2, rate=nu.n*sigma2.n/2)
  }
}

contour(mu, sigma2, apost)

```



```
par(mfrow=c(1,1))
```

### 3.3.2 Aposteriorna porazdelitev pri neinformativni apriorni porazdelitvi

Dobimo:

$$\mu \mid \sigma^2, x \sim N(\bar{x}, \sigma^2/n),$$

Aposteriorno porazdelitev  $\sigma^2$  lahko zapišemo na tri ekvivalentne načine, eden izmed njih:

$$(n-1)s^2/\sigma^2 \mid x \sim \chi_{n-1}^2.$$

Opazimo, da v aposteriorni porazdelitvi  $\mu$  in  $\sigma^2$  nista več neodvisna, ceprav sta bila v apriorni.

Neinformativno porazdelitev si lahko predstavljamo nekako kot, da v konjugirani nastavimo  $\kappa_0$  in  $\nu_0$  na 0.

Zgornji formuli sta dobro znani iz frekventistične statistike.

## 3.4 Ali smo ocenili, kar nas je zanimalo?

Dejansko nas zanima robna (marginalna) aposteriorna porazdelitev  $\mu$ .


### 3.4.1 Robna aposteriorna porazdelitev pri konjugirani apriorni porazdelitvi

V primeru konjugirane apriorne porazdelitve dobimo posplošeno/nestandardizirano Studentovo porazdelitev:

$$\mu \mid x \sim t_{\nu_n}(\mu_n, \sigma_n^2/\kappa_n).$$

Narisemo v R-u:

```
mu <- seq(1.7, 1.9, 0.0001)
aposteriorna <- dt((mu-mu.n)/sqrt(sigma2.n/kappa.n), df = nu.n)/sqrt(sigma2.n/kappa.n)
plot(mu, aposteriorna, type="l", main="Robna aposteriorna porazdelitev",
      xlab = expression(mu), ylab = "")
```



### 3.4.2 Robna aposteriorna porazdelitev pri neinformativni apriorni porazdelitvi

V primeru neinformativne apriorne porazdelitve dobimo posplošeno/nestandardizirano Studentovo porazdelitev:

$$\mu \mid x \sim t_{n-1}(\bar{x}, s^2/n).$$

Oglejmo si, kaj velja za standardizirano odstopanje vzorčnega povprecja od populacijskega povprecja v naslednjih dveh pristopih:

- Bayesova statistika pri neinformativni apriorni porazdelitvi:  $(\mu - \bar{x})/(s^2/n) \mid x \sim t_{n-1}$
- Frekventisticna statistika:  $(\bar{x} - \mu)/(s^2/n) \mid \mu \sim t_{n-1}$

Negotovost o standardiziranemu odstopanju vzorčnega povprecja od populacijskega povprecja torej predstavlja enaka porazdelitev (tj.  $t_{n-1}$ ) preden poznamo podatke (frekventisticna statistika) in po znanih podatkih (Bayesova statistika). Razlika pri tem je, da preden poznamo podatke dejansko ne poznamo niti  $\bar{x}$  niti  $\mu$ , po znanih podatkih pa poznamo  $\bar{x}$ , ki nam informira vedenje o  $\mu$ .

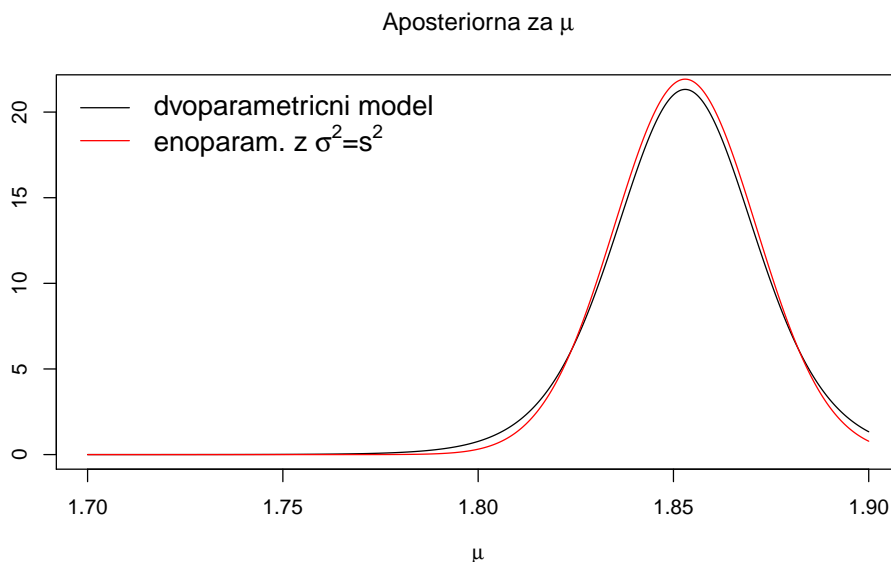
Ce imamo v modelu  $N(\mu, \sigma^2 = 0.1^2)$  neinformativno aposteriorno porazdelitev, potem je

$$\mu \mid x \sim N(\bar{x}, \sigma^2/n) = N(\bar{x}, 0.1^2/n).$$

Primerjamo rezultata iz obeh modelov (neinformativna apriorna v eno- ali dvoparametricnem modelu), kjer se zozimo na podvzorec prvih 10 visin (pri večjem  $n$  razlika ne bi bila tako očitna) in v modelu z znano varianco vzamemo kar  $\sigma^2 = s^2$  (s cimer goljufamo, saj iz vzorca ocenimo varianco, ki naj bi bila znana vnaprej):

```
x.podvzorec <- x[1:10]

mu <- seq(1.7, 1.9, 0.0001)
aposteriorna.neinf <- dt((mu-mean(x.podvzorec))/sqrt(var(x.podvzorec)/n),
                        df = length(x.podvzorec)-1)/sqrt(var(x.podvzorec)/n)
aposteriorna.neinf.sigmaZnan <- dnorm(mu, mean = mean(x.podvzorec),
                                       sd = sqrt(var(x.podvzorec)/n))
plot(mu, aposteriorna.neinf, type="l",
     main=expression(paste("Aposteriorna za ", mu, sep="")),
     xlab = expression(mu), ylab = "")
lines(mu, aposteriorna.neinf.sigmaZnan, col="red")
legend("topleft", legend = c("dvoparametricni model",
                             expression(paste("enoparam. z ", sigma^2, "=", s^2, sep=""))),
     col = c("black", "red"), lty = 1, bty = "n", cex = 1.3)
```



Poanta: Ce goljufamo, potem je nasa ocena za  $\mu$  manj variabilna – premalo variabilna!

### 3.5 Napovedovanje

Zanima nas, kaj lahko povemo o visini novega studenta ob upoštevanju podatkov 30 studentov, tj. zanima nas **aposteriorna napovedna porazdelitev**.

V primeru konjugirane apriorne porazdelitve dobimo posplošeno/nestandardizirano Studentovo porazdelitev:


$$x_{nov} \mid x \sim t_{\nu_n}(\mu_n, \sigma_n^2/\kappa_n + \sigma_n^2).$$

V primeru neinformativne apriorne porazdelitve dobimo posplošeno/nestandardizirano Studentovo porazdelitev:

$$x_{nov} \mid x \sim t_{n-1}(\bar{x}, s^2/n + s^2).$$

Poudarimo bistveno razliko med aposteriornimi porazdelitvijo povprečne visine in aposteriornimi napovednimi porazdelitvijo za visino novega studenta (vzamemo primer s konjugirano apriorno porazdelitvijo):

```
mu <- seq(1.4, 2.2, 0.001)
aposteriorna <- dt((mu-mu.n)/sqrt(sigma2.n/kappa.n), df = nu.n)/sqrt(sigma2.n/kappa.n)
napovedna <- dt((mu-mu.n)/sqrt(sigma2.n/kappa.n+sigma2.n),
                df = nu.n)/sqrt(sigma2.n/kappa.n+sigma2.n)
plot(mu, aposteriorna, type="l",
      xlab = "", ylab = "verjetnost")
lines(mu, napovedna, col="red")
legend("topleft", lty = 1,
      c("aposteriorna", "aposteriorna\nnapovedna"), col = c("black", "red"),
      bty = "n", cex = 1.3)
```






## 4 Naloga

Simulirajte iz aposteriorne porazdelitve, ki jo dobimo za nas primer pri zgoraj izbrani konjugirani apriorni porazdelitvi.

Za dobljeni vzorec narisite histogram s knjižnico `ggplot` in ukazom `stat_bin2d`. Spodaj je primer za simulacijo iz bivariate normalne porazdelitve, katere robni porazdelitvi sta neodvisni.


```
#install.packages("ggplot2")
library(ggplot2)
a <- rnorm(100000, 0, 1)
b <- rnorm(100000, 1, 2)
simulacija <- data.frame(a, b)
ggplot(simulacija, aes(a, b)) + stat_bin2d()
```



Resitev:

```
prec.sample <- rgamma(100000, nu.n/2, nu.n*sigma2.n/2)
mu.sample <- rnorm(100000, mu.n, sd = sqrt(1/(kappa.n*prec.sample)))

pod <- data.frame(mu.sample, prec.sample)
ggplot(pod, aes(mu.sample, prec.sample)) + stat_bin2d()
```



```
ggplot(pod, aes(mu.sample, 1/prec.sample)) + stat_bin2d()
```

