

Domača naloga 1

Linearni modeli

Alen Kahteran

22 11 2020

Simulacija za enostavno linearno regresijo

```
# določitev beta0, beta1 in stevilo simulacij
b_0 <- 100
b_1 <- 1
N_sim <- 1000
# določitev n in sigma
n_sizes <- c(7, 15, 30, 100)
s_sizes <- c(5, 11, 22)

# vse možne kombinacije
combinations <- expand.grid(n_sizes, s_sizes)
# preimenujemo
names(combinations) <- c("n", "s")
# list za zhranjevanje
storage <- list()

# funkcija
reg.sim <- function(x, beta0, beta1, sigma, Nsim) {
  # pripravimo prazne vektorje za rezultate simulacij, cenilke parametrov b0 in b1,
  # p-vrednost za testiranje domneve beta1=0,
  # spodnjo in zgornjo mejo intervala zaupanja za beta1
  b0 <- numeric(Nsim)
  b1 <- numeric(Nsim)
  p <- numeric(Nsim)
  sp.meja.b1 <- numeric(Nsim)
  zg.meja.b1 <- numeric(Nsim)
  n <- length(x)

  for (i in 1:Nsim) {
    epsilon <- rnorm(n, mean=0, sd=sigma)
    y <- beta0 + beta1 * x + epsilon
    mod <- lm(y ~ x)
    b0[i] <- coef(mod)[1]
    b1[i] <- coef(mod)[2]
    p[i] <- coefficients(summary(mod))[2, 4]
    sp.meja.b1[i] <- confint(mod)[2, 1]
    zg.meja.b1[i] <- confint(mod)[2, 2]
  }
}
```

```

    return(data.frame(b0, b1, p, sp.meja.b1, zg.meja.b1))
}

# dolocimo seme za ponovljivost
set.seed(8)

# zanka cez vse n-je in sigme
for (row in 1:nrow(combinations)){
  # za lepsi izpis
  n_ <- combinations[row, "n"]
  s_ <- combinations[row, "s"]
  # shranimo v storage
  storage[paste0("n", n_, "s", s_)] <- list(reg.sim(sample(15:70, n_, replace=TRUE),
                                                    b_0,
                                                    b_1,
                                                    s_,
                                                    N_sim) %>%
                                                    # dodamo n in s vrednosti za izris
                                                    mutate(n = n_,
                                                           s = s_))
}


# pretvorimo v korekten format
full_data <- unnest(tibble(storage), cols = c(storage))

# izracunamo stvari po skupinah za izris
full_data <- full_data %>%
  group_by(n, s) %>%
  mutate(mean_b1 = mean(b1),
         mean_sp_b1 = mean(sp.meja.b1),
         mean_zg_b1 = mean(zg.meja.b1),
         test_power = 1-sum(p>0.05)/N_sim) %>%
  ungroup()

# izris beta1 od n, za razlicne sigma
ggplot(full_data, aes(x=n, y=mean_b1)) +
  geom_errorbar(aes(ymin=mean_sp_b1, ymax=mean_zg_b1)) +
  facet_grid(cols=vars(s)) +
  labs(y = TeX("$\\beta_1$"),
       title = TeX("Odvisnost $\\beta_1$ od $n$, ko je $\\sigma$ enak 5, 11 ali 22."))


```

Odvisnost β_1 od n , ko je σ enak 5, 11 ali 22.




```
# izris beta1 od sigma, za razlicne n
ggplot(full_data, aes(x=s, y=mean_b1)) +
  geom_errorbar(aes(ymin=mean_sp_b1, ymax=mean_zg_b1)) +
  facet_grid(cols=vars(n)) +
  labs(y = TeX("$\\beta_1$"),
       title = TeX("Odvisnost $\\beta_1$ od $\\sigma$, ko je $n$ enak 7, 15, 30 ali 100."))
```

Odvisnost β_1 od σ , ko je n enak 7, 15, 30 ali 100.




```
# izris moci testa od n, za razlicne sigma
ggplot(full_data, aes(x=n, y=test_power)) +
  geom_line() +
  geom_point() +
  facet_grid(cols=vars(s)) +
  labs(y = "Moč testa",
       title = TeX("Odvisnost moci od $n$, ko je $\\sigma$ enak 5, 11 ali 22."))
```

Odvisnost moci od n , ko je σ enak 5, 11 ali 22.



```
# izris moci testa od sigma, za razlicne n
ggplot(full_data, aes(x=s, y=test_power)) +
  geom_line() +
  geom_point() +
  facet_grid(cols=vars(n)) +
  labs(y = "Moč testa",
       title = TeX("Odvisnost moci od  $\sigma$ , ko je  $n$  enak 7, 15, 30 ali 100."))
```

Odvisnost moci od σ , ko je n enak 7, 15, 30 ali 100.



Iz prvega grafa je razvidno, da ko večamo velikost vzorca se pri enakem σ interval zaupanja manjša, kar je smiselno, saj iz več podatkov bolje napovemo β_1 . Vidno je tudi da je interval zaupanja glede na σ večji, saj σ predstavlja kolikšen bo mogoč odklon pri izračunu. Kar je pravzaprav še bolj vidno na drugem grafu, kjer je n fiksiran. Poleg tega je videti da se za večje n vrednosti interval zaupanja manjša, kar smo videli tudi že na prvem grafu.

Pri grafih moči je videti, da se zna kdaj zgoditi, da pri večjih σ in pri manjših n -jih, da ničelne hipoteze ne zavrnemo. To je zelo dobro razvidno iz zadnjega grafa, kjer je videti da se pri majhnem n večkrat zgodi da ničelne hipoteze ne zavrnemo. Poleg tega je videti da pri majhnih n vrednostih je pomembno da je tudi σ majhen, če želimo ničelno hipotezo zavrniti, kar pri velikih n -jih ne velja, ker je praktično vseeno kolikšen je σ (za naše primere).